Wprowadzenie do uczenia maszynowego

Igor Wojnicki

June 20, 2022

Plan prezentacji

Czym jest Uczenie Maszynowe?

Jak działa Uczenie Maszynowe

Wczesne zastosowania

1

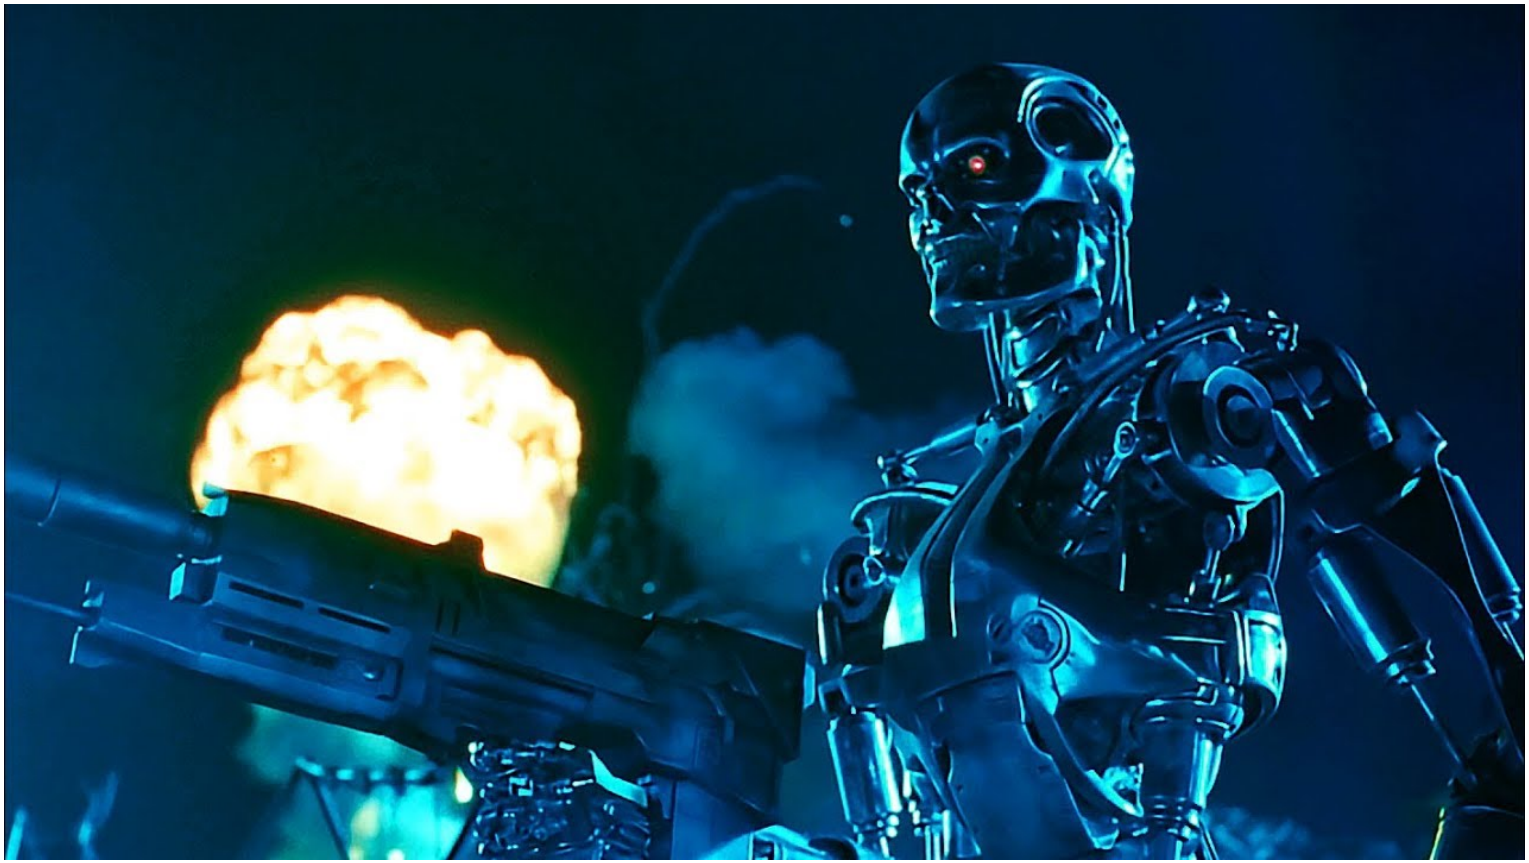

- OCR
- spam filter
- czołgi?

[1] Terminator 2: Judgment Day

Referencje

- Książki
  - Aurelien Geron, *Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, O'Reilly
- Narzędzia `https://www.python.org/` `https://scikit-learn.org` `https://keras.io/` `https://www.tensorflow.org/`

Co to?

- ML is the science and art of programming computers so they *learn from data*.
- . . . a filed of study that gives computers the ability to learn without being explicitelly programmed.
  – Arthur Samuel, 1959
- A computer program is said to learn from experience E with respect to some task T and some pperformance measure P, if its performance on T, as measured by P, improves with experience E.
  – Tom Mitchell, 1997

Dlaczego – podejście tradycyjne.

2

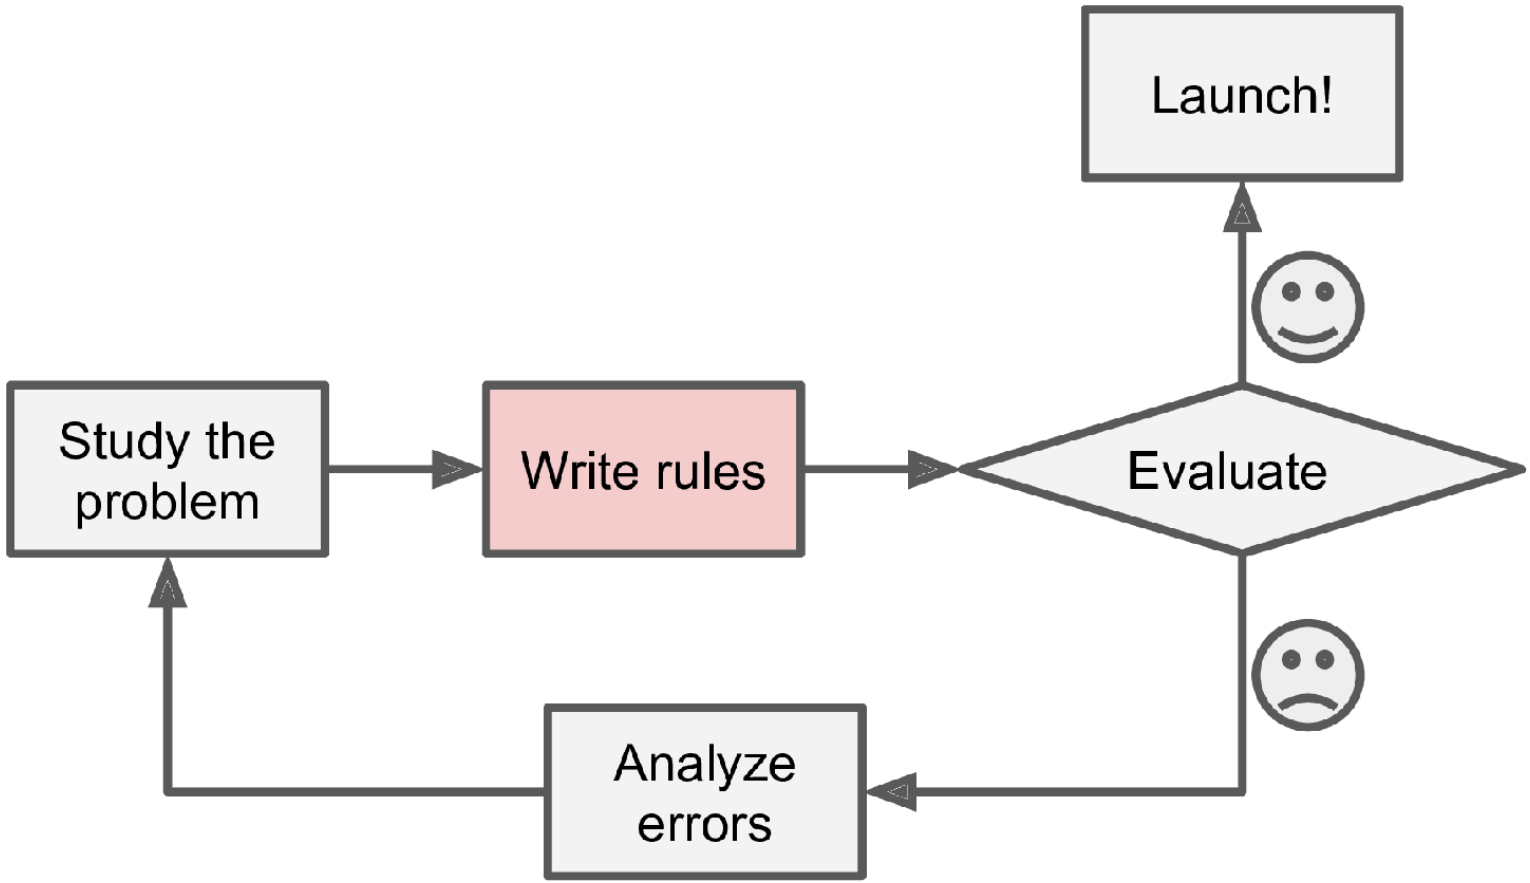

[2] Rys. z: Aurelien Geron, *Hands-on Machine Learning*

Dlaczego – Uczenie Maszynowe

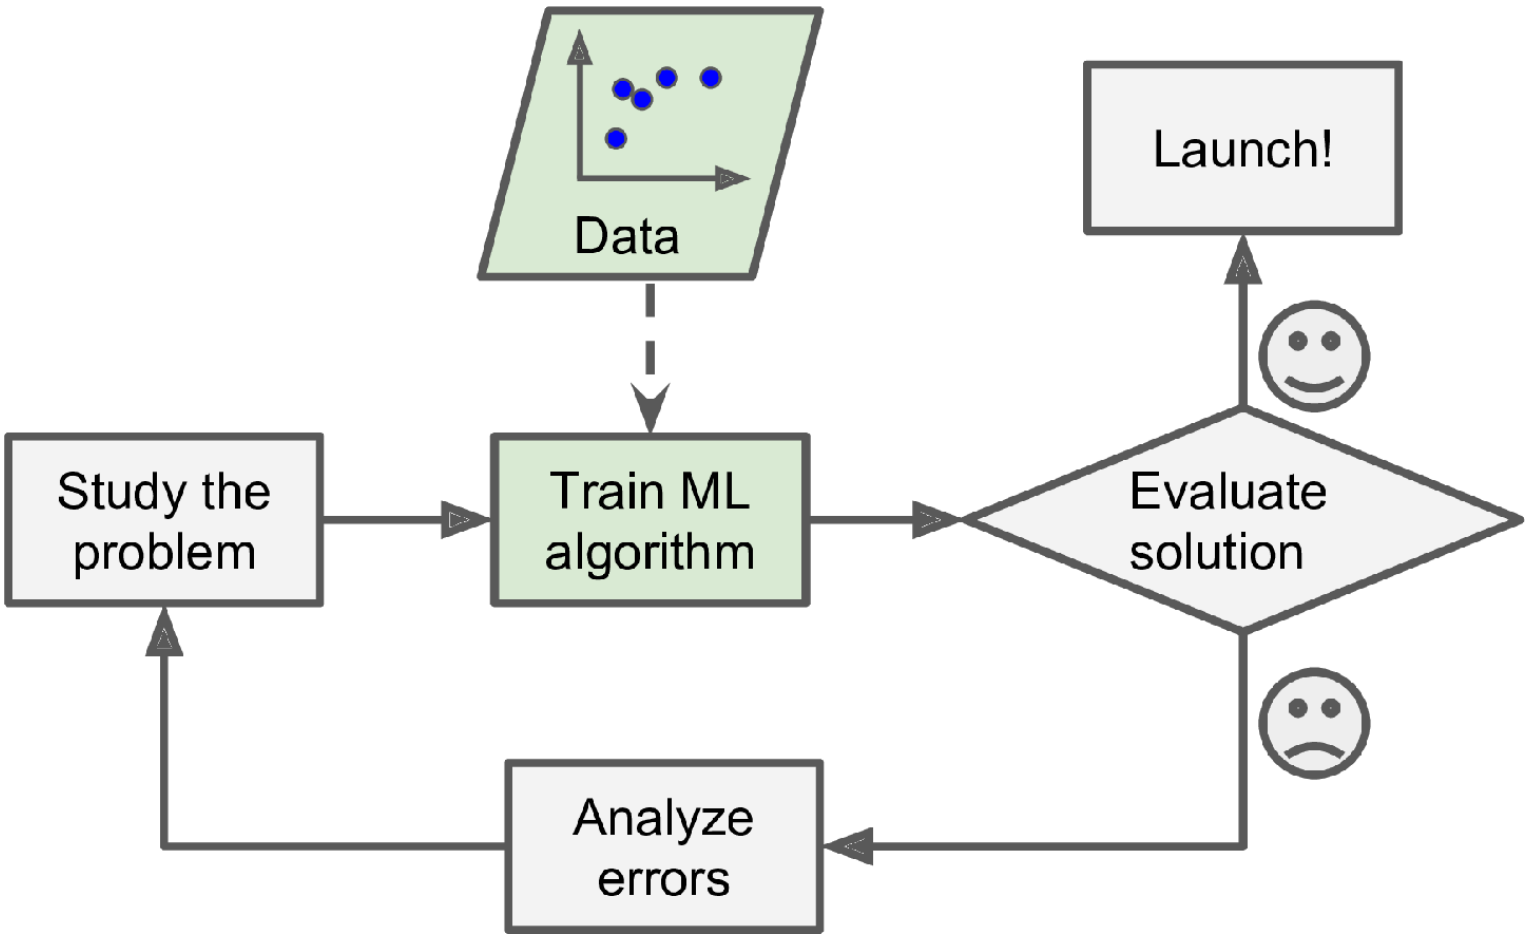

Zaleta – dostosowanie do zmieniających się warunków

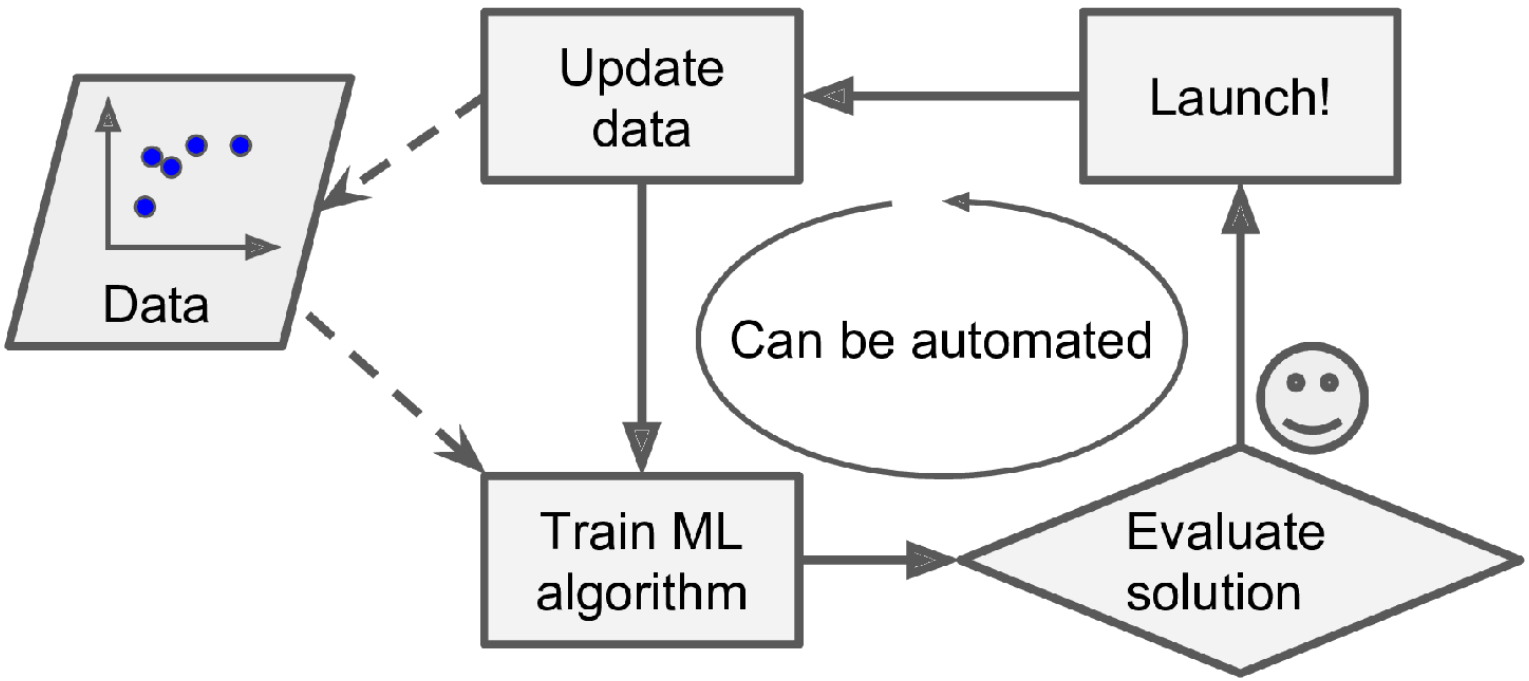

Zaleta – odkrywanie wiedzy

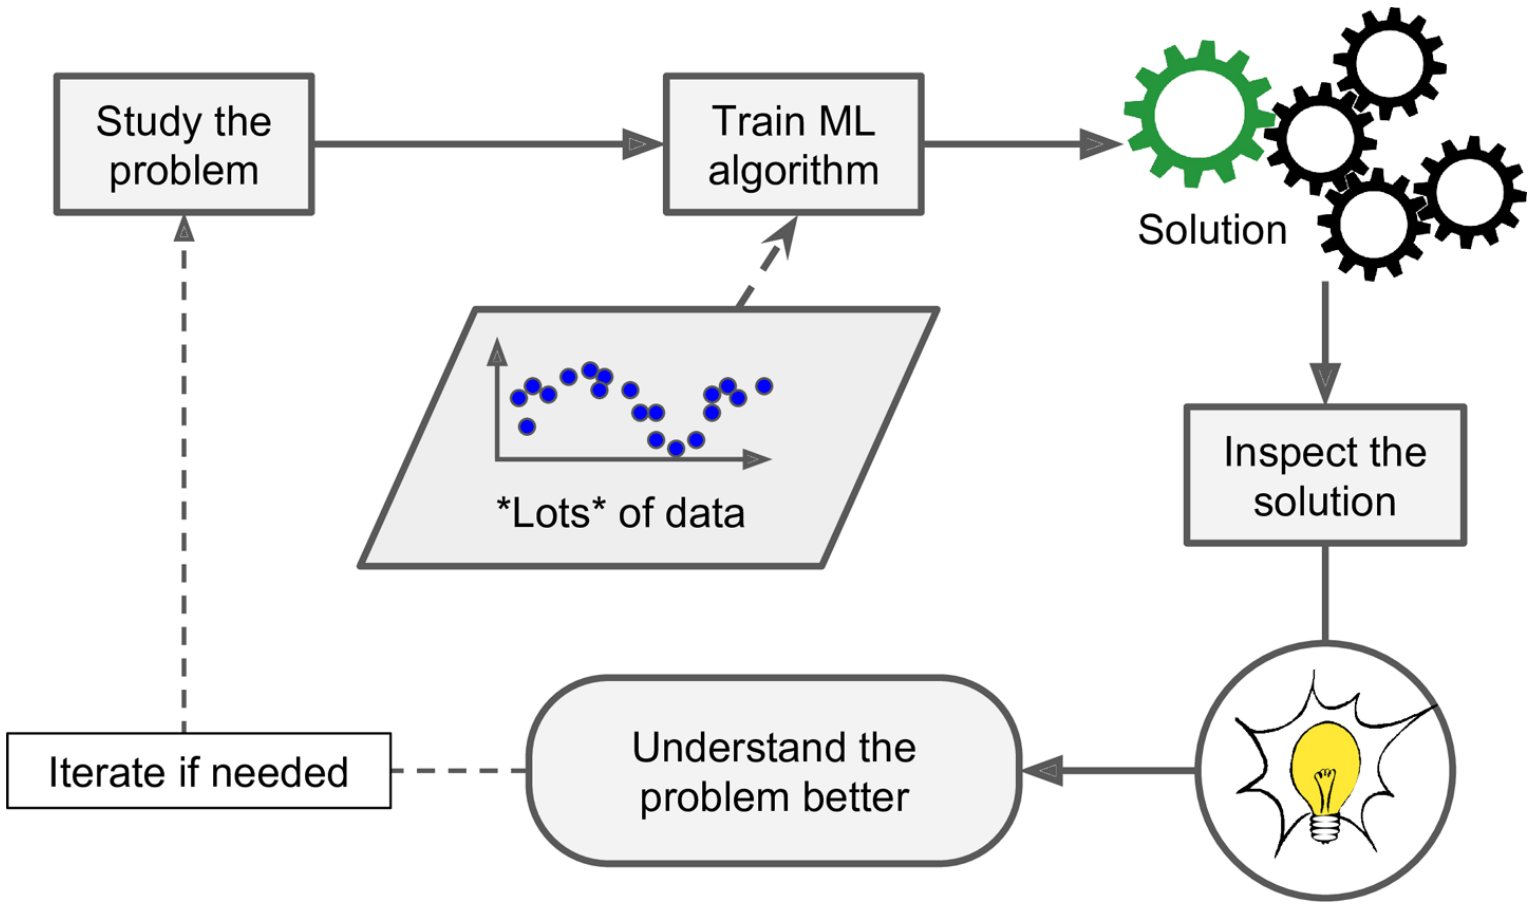

Przykłady

- klasyfikacja produktów na taśmie produkcyjnej, sieci neuronowe CNN,
- wykrywanie schorzeń, sieci neuronowe CNN,
- klasyfikacja tekstów, sieci neuronowe CNN, RNN,
- streszczenia tekstów, sieci neuronowe CNN, RNN,
- dialog (asystent głosowy) i rozpoznawanie mowy,
- przewidywanie np. przychodu w firmie, regresja,
- wykrywanie oszustw finansowych,
- segmentacja klientów, klasteryzacja,
- reprezentacja danych wielowymiarowych w zrozumiały sposób, redukcja wymiarów,
- rekomendacje produktów, filmów itp.

Rodzaje – ze względu na nadzór

- nadzorowane – trzeba etykietować zbiór uczący,
- nienadzorowane – nie trzeba etykietować zbioru uczącego (uczenie bez nauczyciela),
- częściowo nadzorowane,
- uczenie przez wzmacnianie (reinforcement).

Nadzorowane – klasyfikacja

Czy wiadomość jest spamem czy nie?

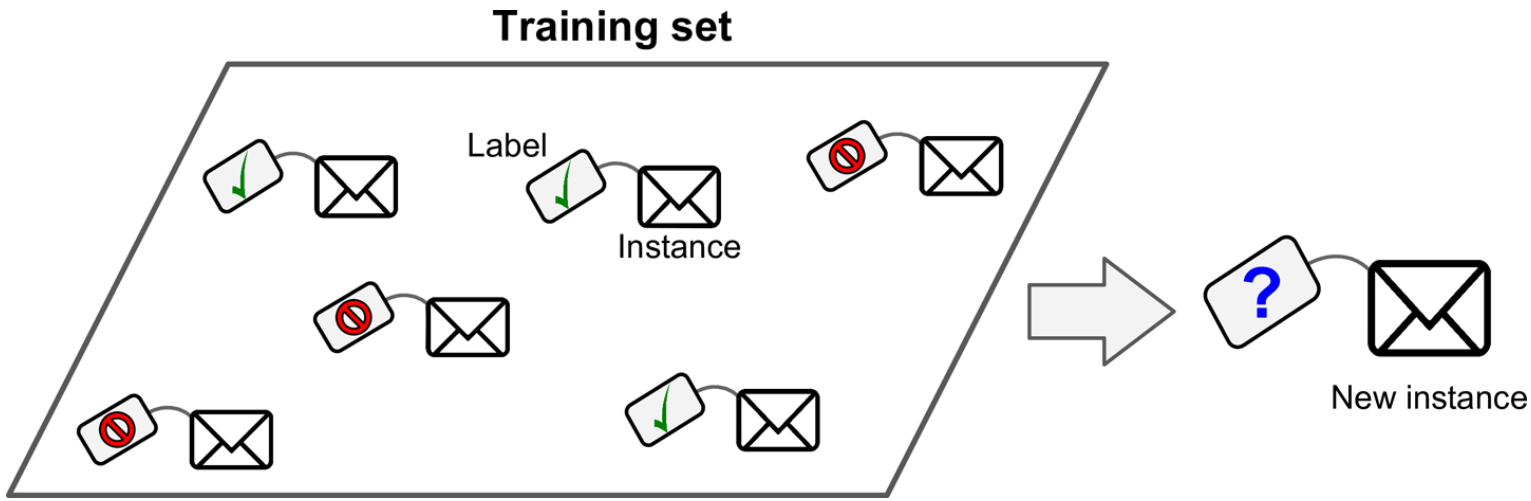

Nadzorowane – regresja

Jaka jest cena samochodu biorąc pod uwagę jego przebieg?

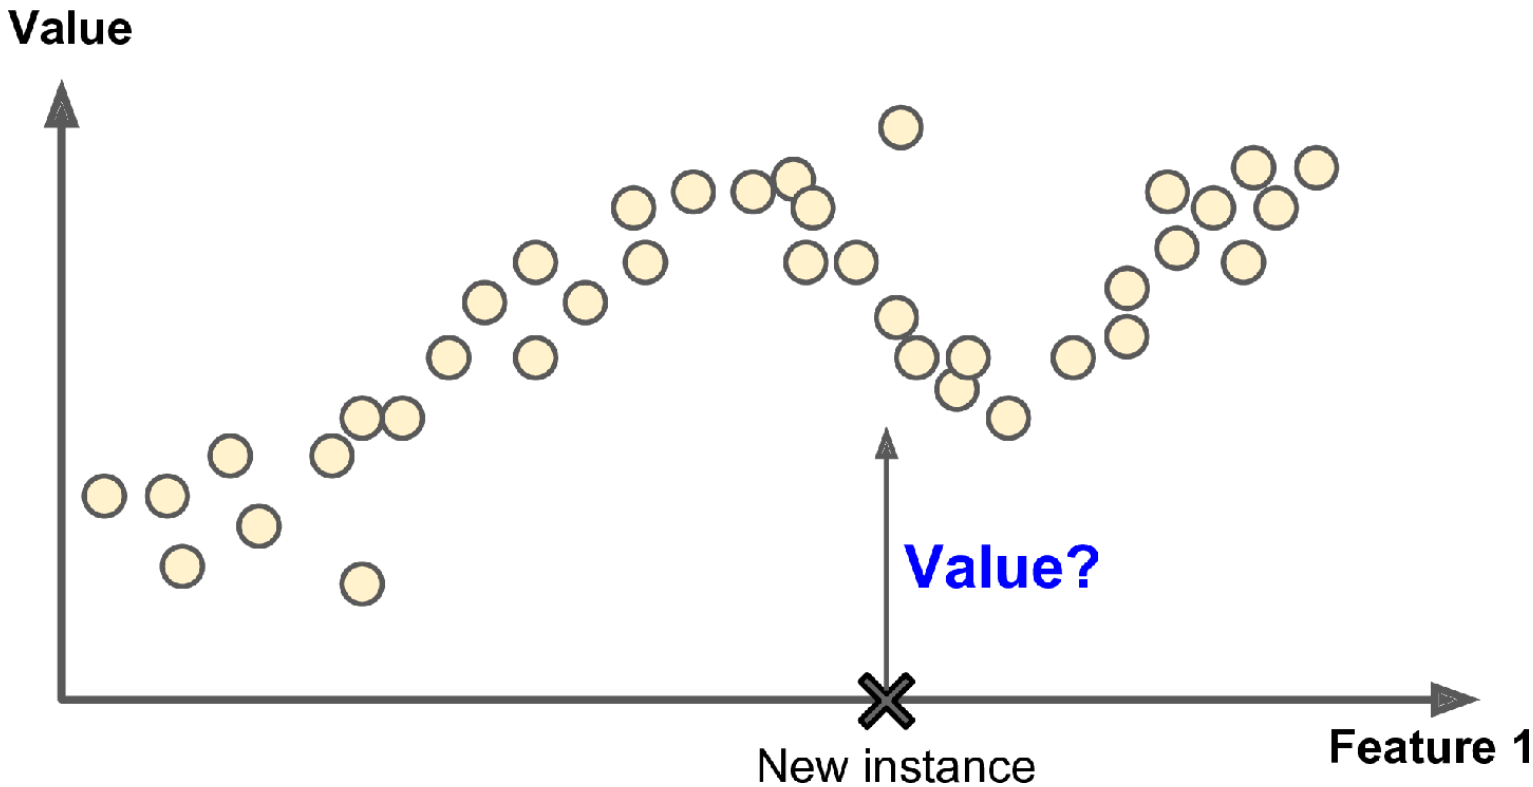

Nienadzorowane – klasteryzacja, przed

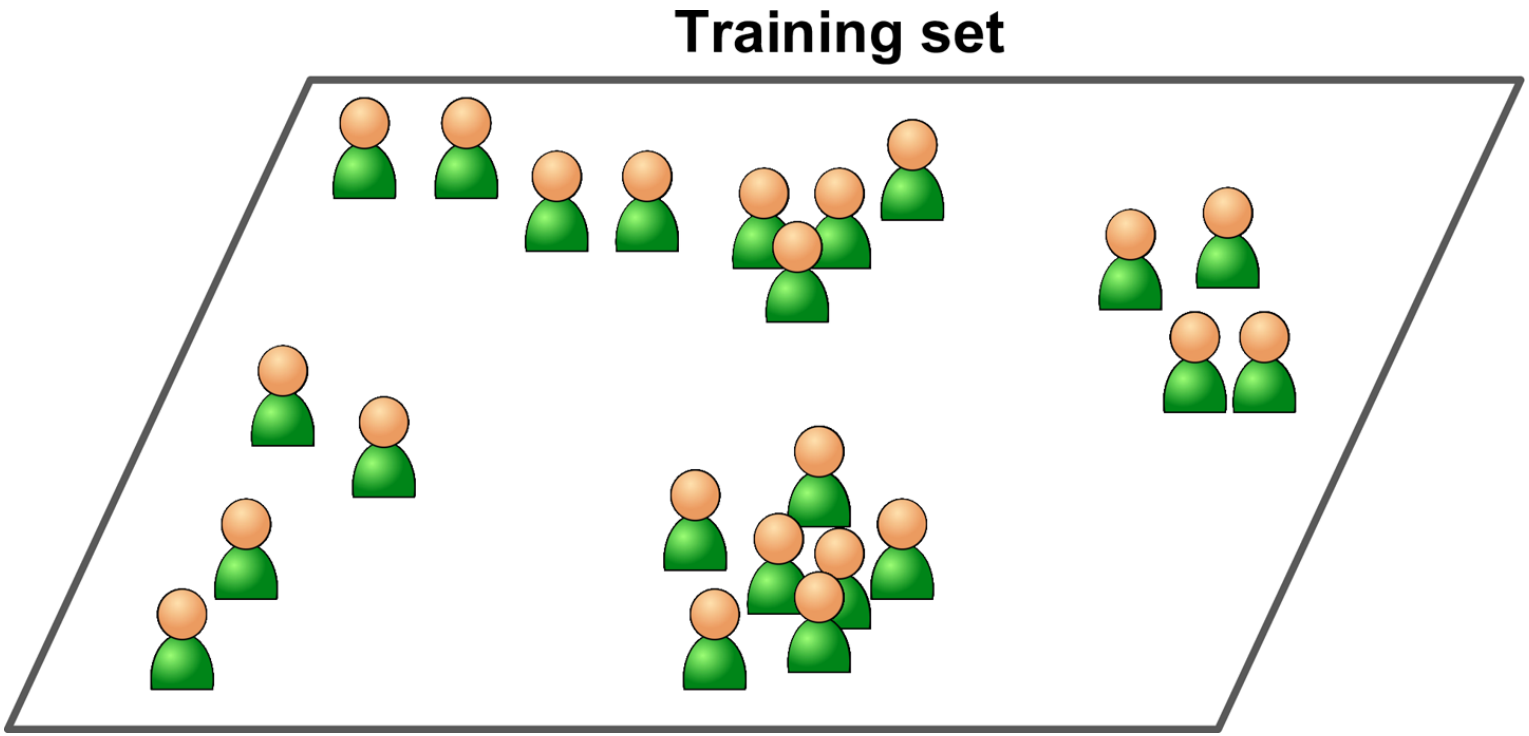

Nienadzorowane – klasteryzacja, po

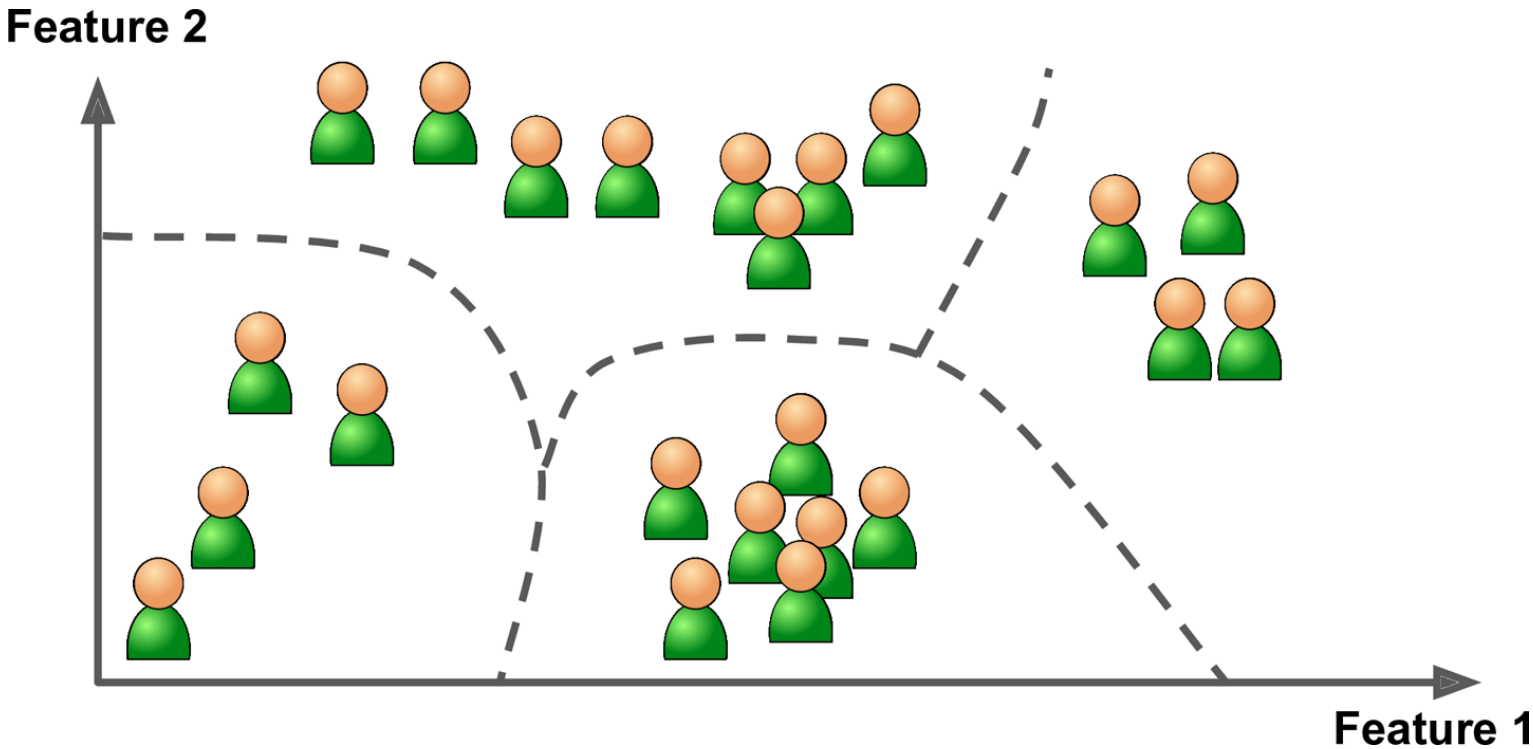

Nienadzorowane – detekcja anomalii

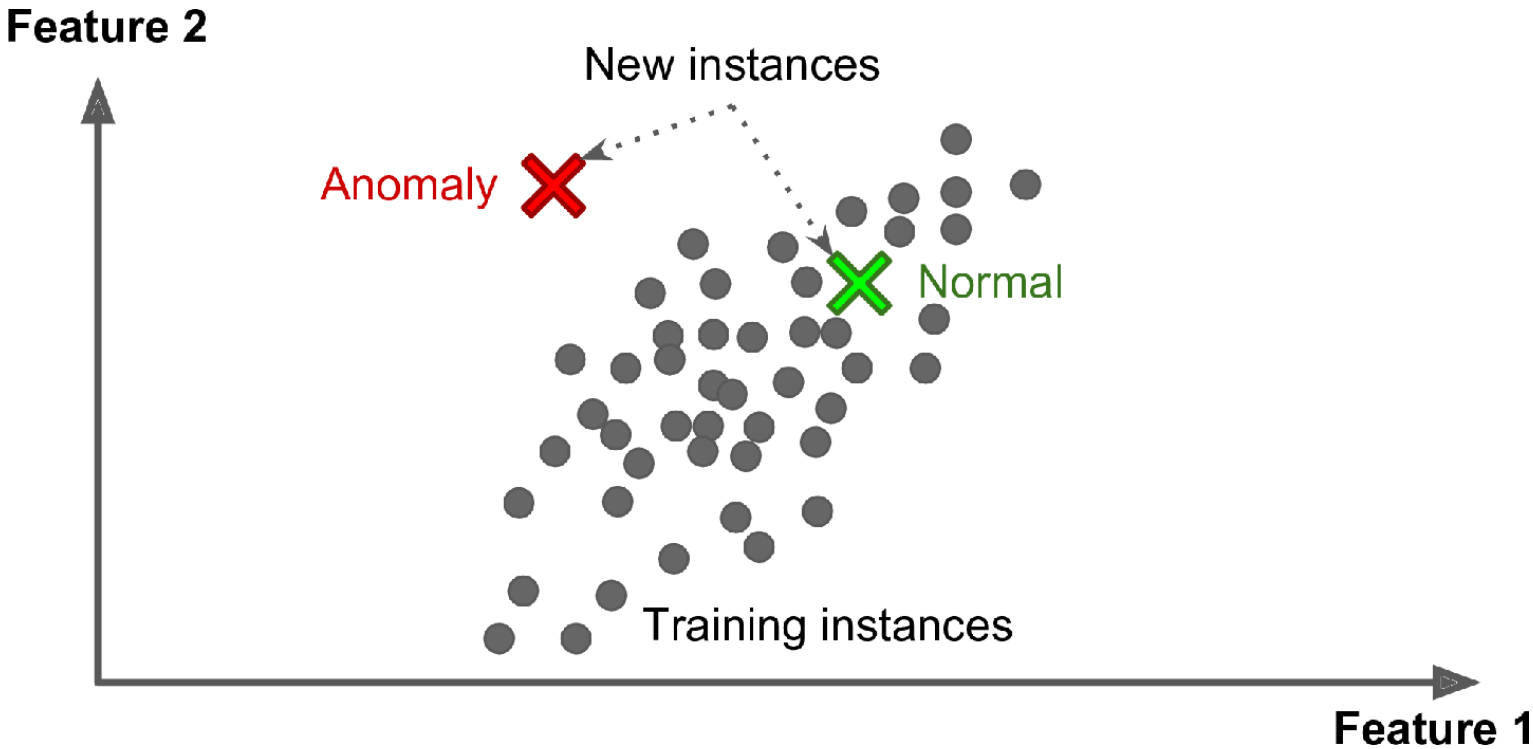

Częściowo nadzorowane

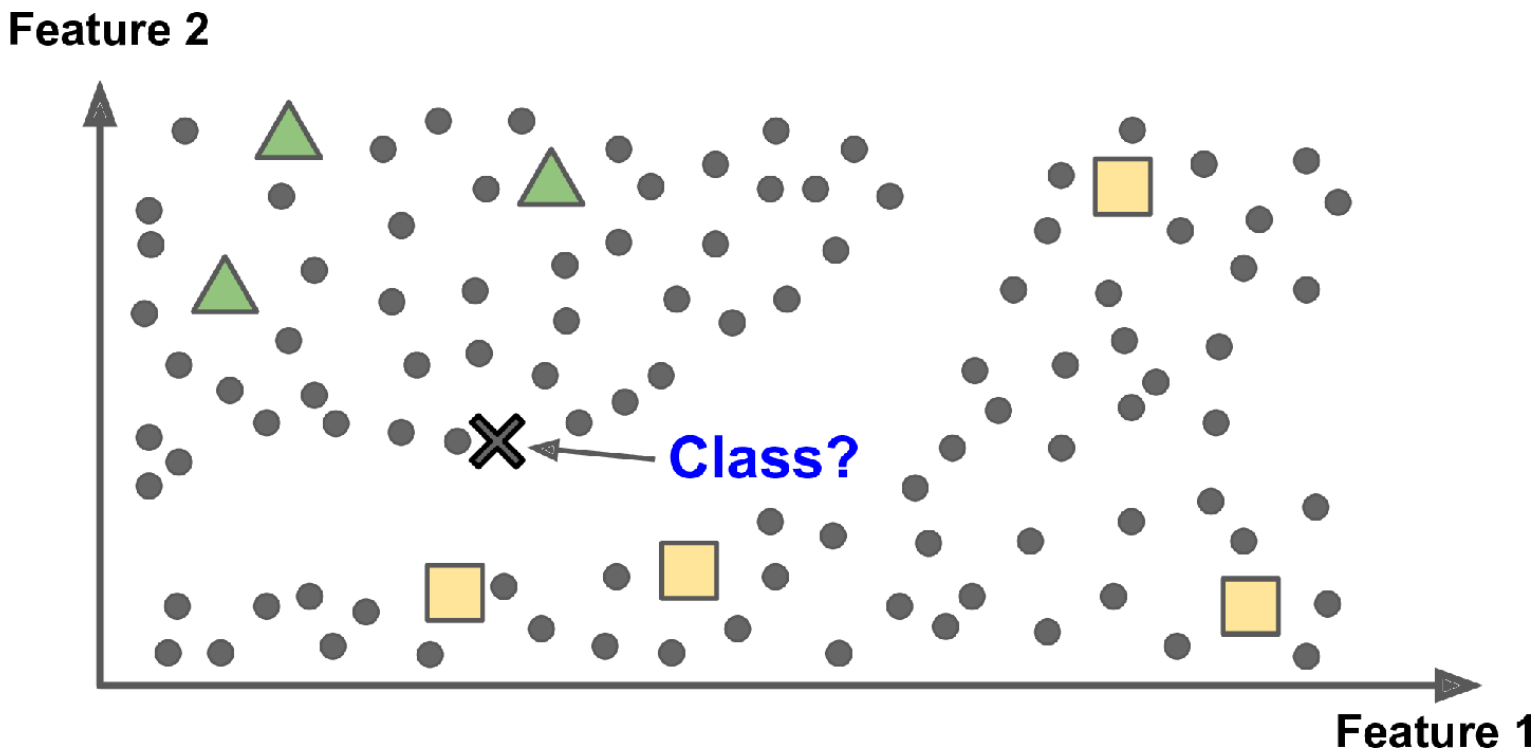

Zwykle połączenie metod nienadzorowanych i nadzorowanych.

Uczenie przez wzmacnianie

Obserwator jest karany lub nagradzany.

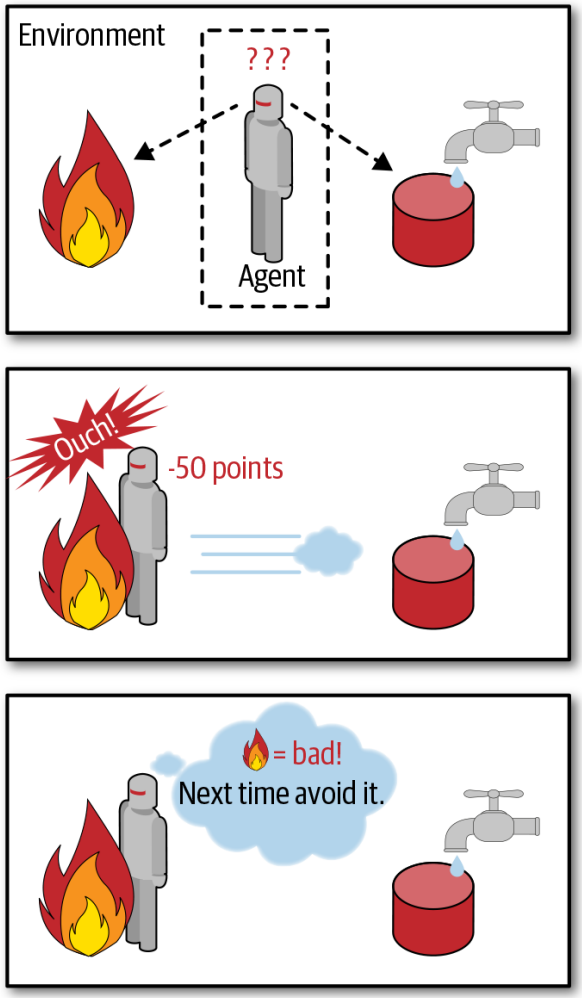

1. Observe
2. Select action using policy
3. Action!
4. Get reward or penalty
5. Update policy (learning step)
6. Iterate until an optimal policy is found

Rodzaje ze względu na dostęp do danych

- batch,
  - uczenie na podstawie kompletnego zbioru danych,
- online (mini-batches),
  - uczenie przyrostowe,
  - umożliwia out-of-core learning – uczenie gdy dane treningowe nie mieszczą się w pamięci.

Rodzaje ze względu na sposób uogólnienia

oparte o:

- instancje – tzw. model nieparametryczny,
- model – tzw. model parametryczny.

Sposób uogólnienia – instancja

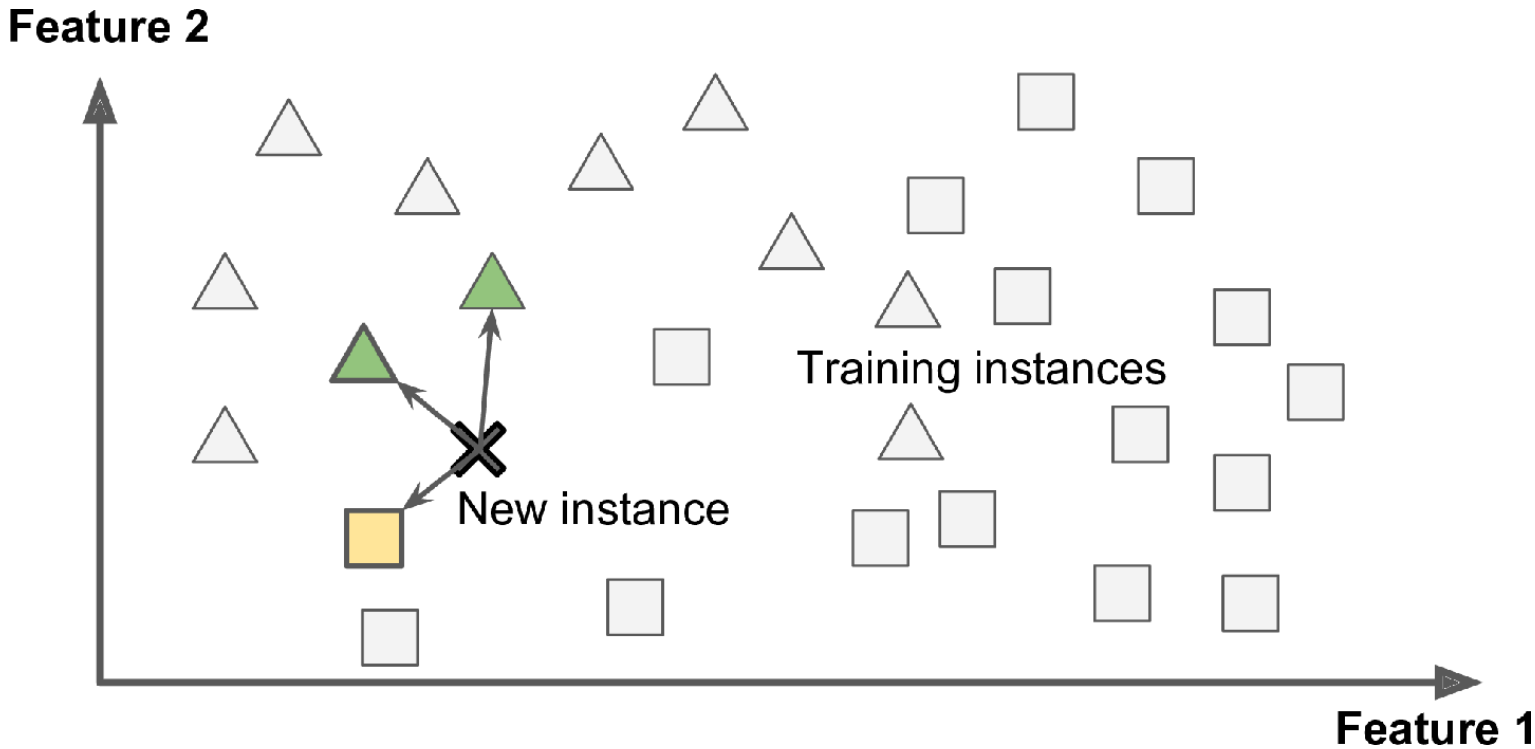

Sposób uogólnienia – model

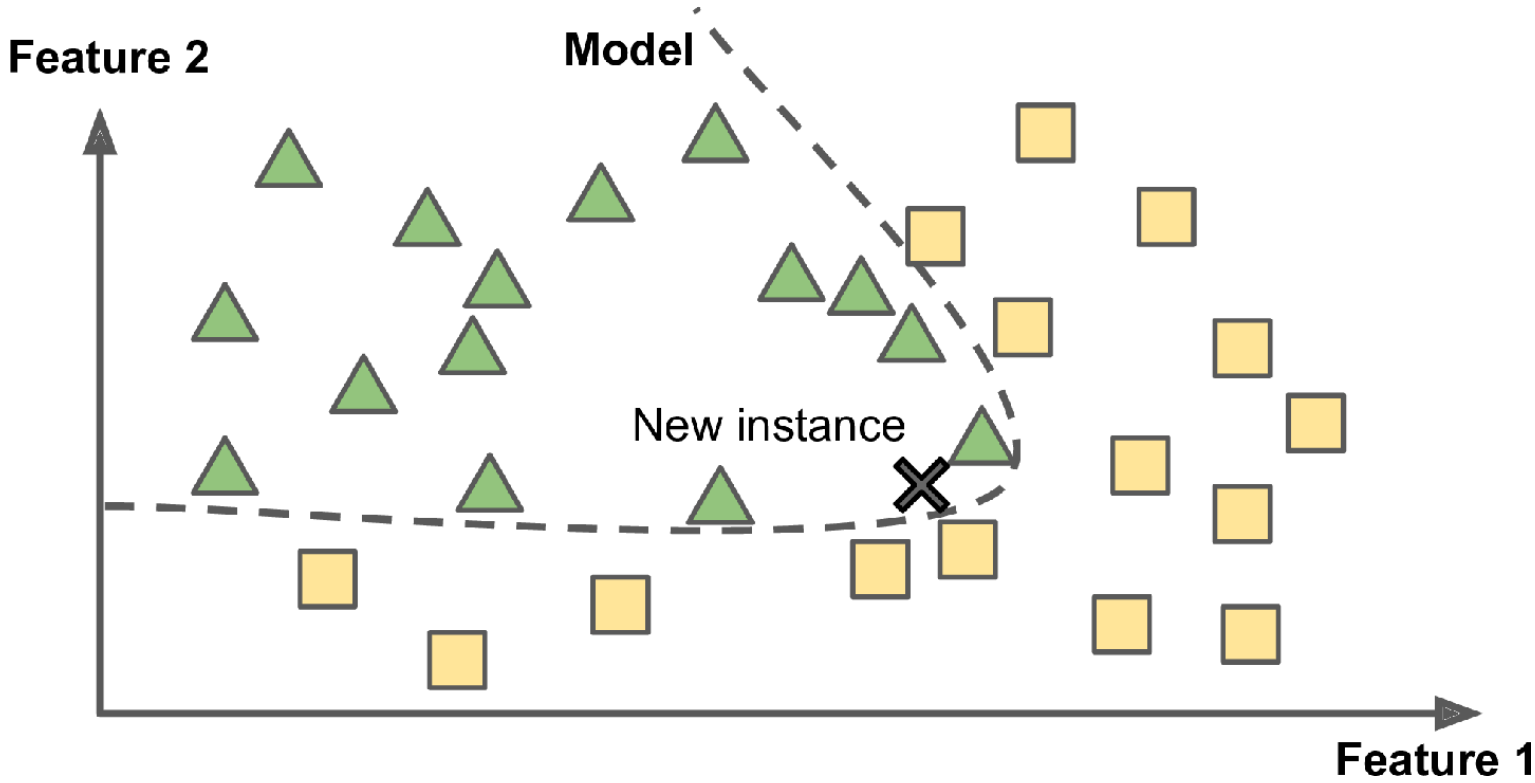

Wyzwania Uczenia Mszynowego

1. wybrać odpowiedni uczący,
   - overfitting (nadmierne dopasowanie / przeuczenie),
   - underfitting (niedouczenie: nieodpowiedni model dla danych, np. zastosowanie modelu liniowego do nieliniowych danych),
2. wybrać odpowiednie dane do uczenia,
   - za mało danych,
   - niereprezentatywne dane,
   - dane niskiej jakości,
   - nieistotne cechy/dane,

Testowanie

- Dane uczące (training set),
- Dane testujące (test set).
- Dane uczące -> oszacowanie *błędu uczenia*.
- Dane testujące -> otrzymamy oszacowanie *błędu generalizacji* (generalization/out-of-sample error).

Błąd uczenia niski, błąd generalizacji wysoki -> overfitting.
Częste proporcje zbiór uczący – zbiór testujący: 80%–20%

Overfitting

- Model działa dobrze na danych uczących, ale niezbyt dobrze generalizuje (marnie działa na danych testujących).
- Model zbyt złożony w kontekście danych uczących i ewentualnego szumu.
- Rozwiązania:
  - uprościć model (wybierz taki, który mam mniej parametrów np. liniowy zamiast wielomianowy),
    - zmniejszenie liczby atrybutów,
    - ograniczenie modelu (o ile algorytm na to pozwala, zwykle jest to tzw. hiperparametr tzn. parametr algorytmu a nie modelu),
  - zebrać więcej danych,
  - zmniejszyć szum w danych uczących (naprawić błędy, usunąć *outliers*).

Który z dwóch modeli/algorytmów jest lepszy?

- Trzeba nauczyć oba.
- Porównać wyniki.

No Free Lunch Theorem

– David Wolpert, 1996.

- Nie znając założeń odnośnie danych, nie można powiedzieć, który model/algorytm będzie działał najlepiej.
- Więc trzeba sprawdzić jak działa każdy z nich.
- W praktyce należy poczynić założenia odnośnie danych i na tej podstawie wybrać zbiór modeli/algorytmów do sprawdzenia.

Plan prezentacji

Czym jest Uczenie Maszynowe?

Jak działa Uczenie Maszynowe

Etapy projektu ML

1. Zastanów się co masz zrobić.
2. Zdobądź dane.
3. Oglądnij dane; wizualizacja.
4. Przygotuj dane.
5. Wybierz model i go wytrenuj.
6. Popraw parametry modelu (fine tune).
7. Wdrożenie, monitoring, utrzymanie.

Dane

bash

```
zcat data/housing.csv.gz | head -4
```

```
longitude,latitude,housing_median_age,total_rooms,total_bedr
-122.23,37.88,41.0,880.0,129.0,322.0,126.0,8.3252,452600.0,N
-122.22,37.86,21.0,7099.0,1106.0,2401.0,1138.0,8.3014,358500
-122.24,37.85,52.0,1467.0,190.0,496.0,177.0,7.2574,352100.0
```

Kolumny:

longitude, latitude, housing_median_age, total_rooms, total_bedrooms, population, households, median_income, median_house_value, ocean_proximity

Dane

```
1  import csv
2  import pandas as pd
3
4  df = pd.read_csv('data/housing.csv.gz')
5  print(df.head())
```

```
   longitude  latitude  housing_median_age  total_rooms  tot
0    -122.23     37.88                41.0        880.0
1    -122.22     37.86                21.0       7099.0
2    -122.24     37.85                52.0       1467.0
3    -122.25     37.85                52.0       1274.0
4    -122.25     37.85                52.0       1627.0
```

Dane

```
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
 #   Column              Non-Null Count  Dtype  
---  ------              --------------  -----  
 0   longitude           20640 non-null  float64
 1   latitude            20640 non-null  float64
 2   housing_median_age  20640 non-null  float64
 3   total_rooms         20640 non-null  float64
 4   total_bedrooms      20433 non-null  float64
 5   population          20640 non-null  float64
 6   households          20640 non-null  float64
 7   median_income       20640 non-null  float64
 8   median_house_value  20640 non-null  float64
 9   ocean_proximity     20640 non-null  object 
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

Dane

```
print(df["ocean_proximity"])
```

```
0         NEAR BAY
1         NEAR BAY
2         NEAR BAY
3         NEAR BAY
4         NEAR BAY
             ...
20635       INLAND
20636       INLAND
20637       INLAND
20638       INLAND
20639       INLAND
Name: ocean_proximity, Length: 20640, dtype: object
```

Dane

```
print(df["ocean_proximity"].value_counts())
```

```
<1H OCEAN     9136
INLAND        6551
NEAR OCEAN    2658
NEAR BAY      2290
ISLAND           5
Name: ocean_proximity, dtype: int64
```

Dane

```
print(df.describe())
```

```
          longitude      latitude  housing_median_age   tota
count  20640.000000  20640.000000        20640.000000  2064
mean    -119.569704     35.631861           28.639486   263
std        2.003532      2.135952           12.585558   218
min     -124.350000     32.540000            1.000000     
25%     -121.800000     33.930000           18.000000   144
50%     -118.490000     34.260000           29.000000   212
75%     -118.010000     37.710000           37.000000   314
max     -114.310000     41.950000           52.000000  3932
```

Dane

```
1 import matplotlib.pyplot as plt
2 df.hist(bins=50, figsize=(20,15))
3 f = "housing_hist.png"
4 plt.tight_layout()
5 plt.savefig(f)
6 print(f)
```

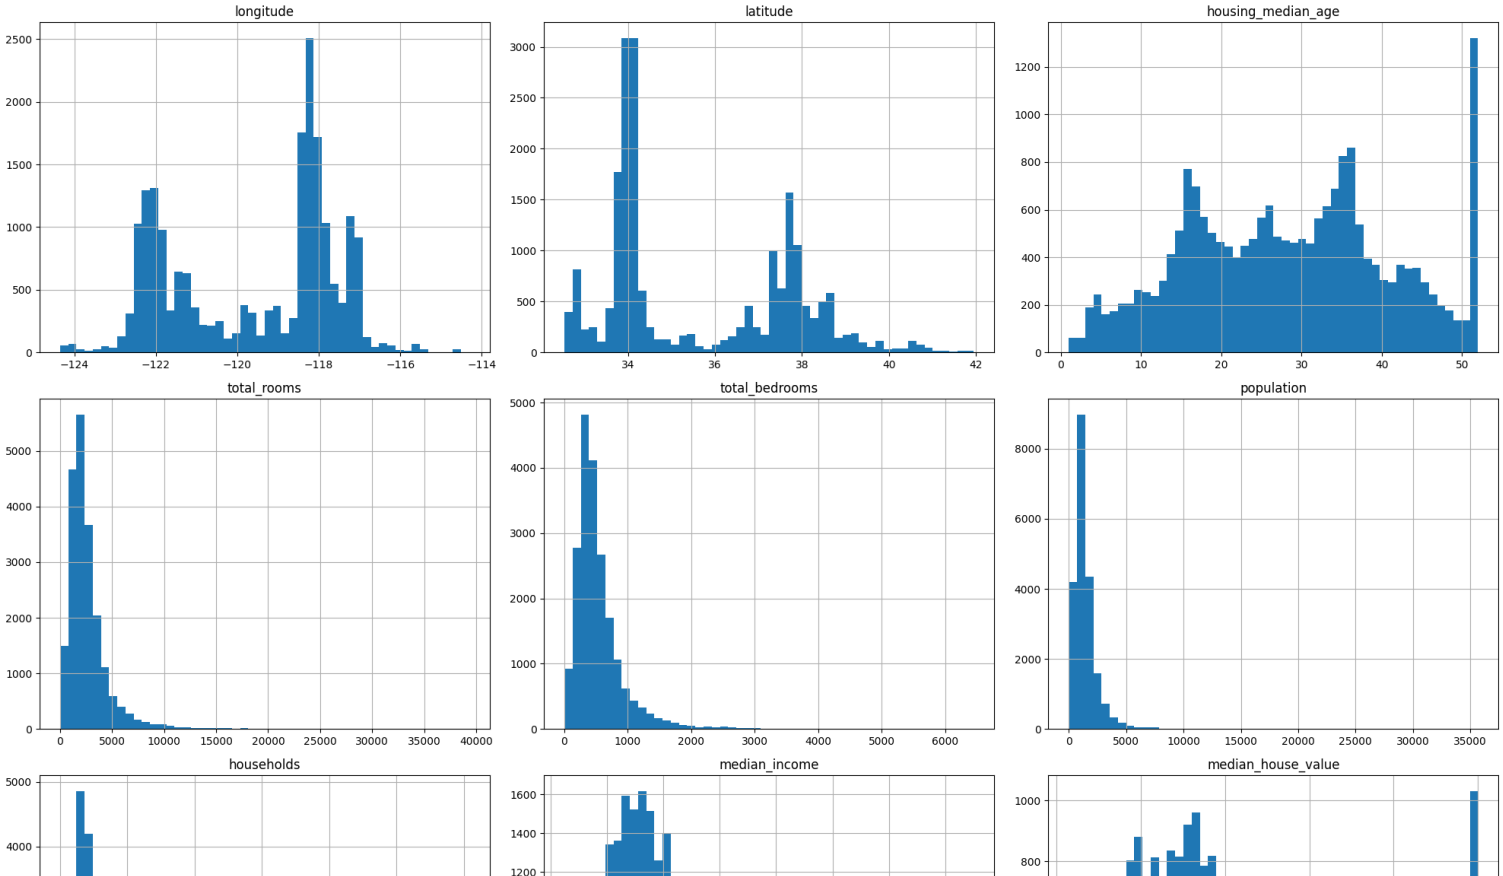

Dane, histogram

median_income – jednostka?, housing_median_age, median housing_value – odcięte od góry, ogólnie – nie są dzwonowe

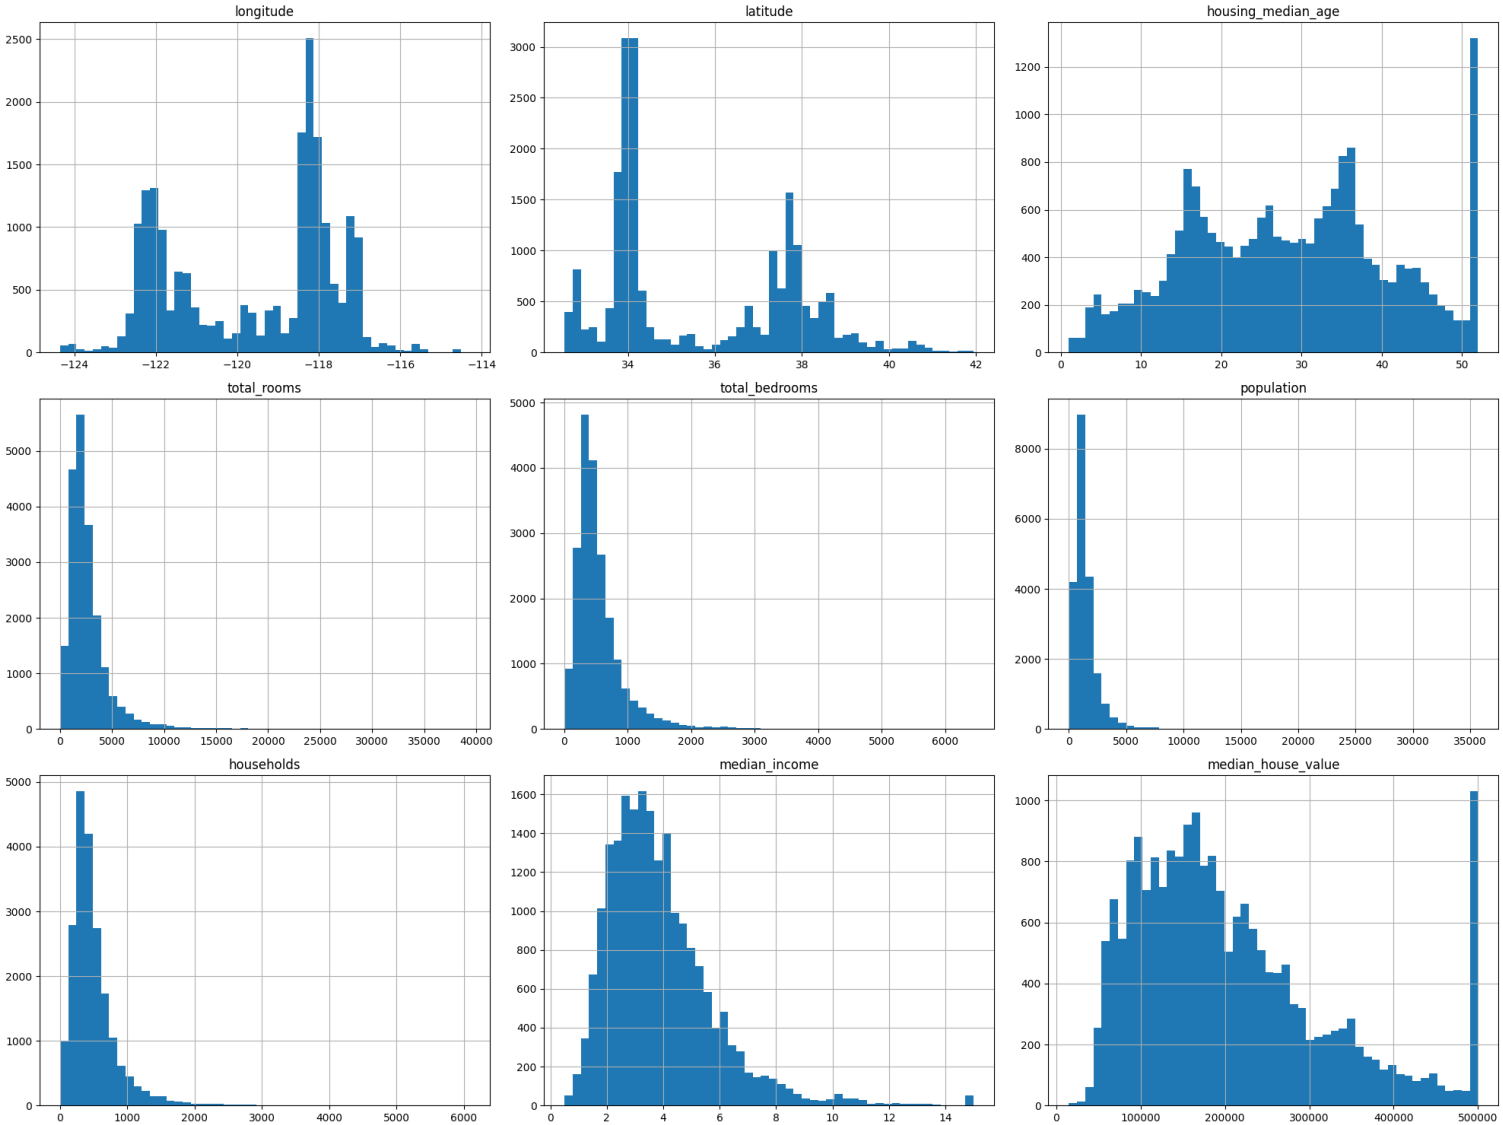

Dane, położenie geograficzne

```
df.plot(kind="scatter", x="longitude", y="latitude",
        alpha=0.1, figsize=(7,4))
f = "housing_lon_lan.png"
plt.tight_layout()
plt.savefig(f)
print(f)
```

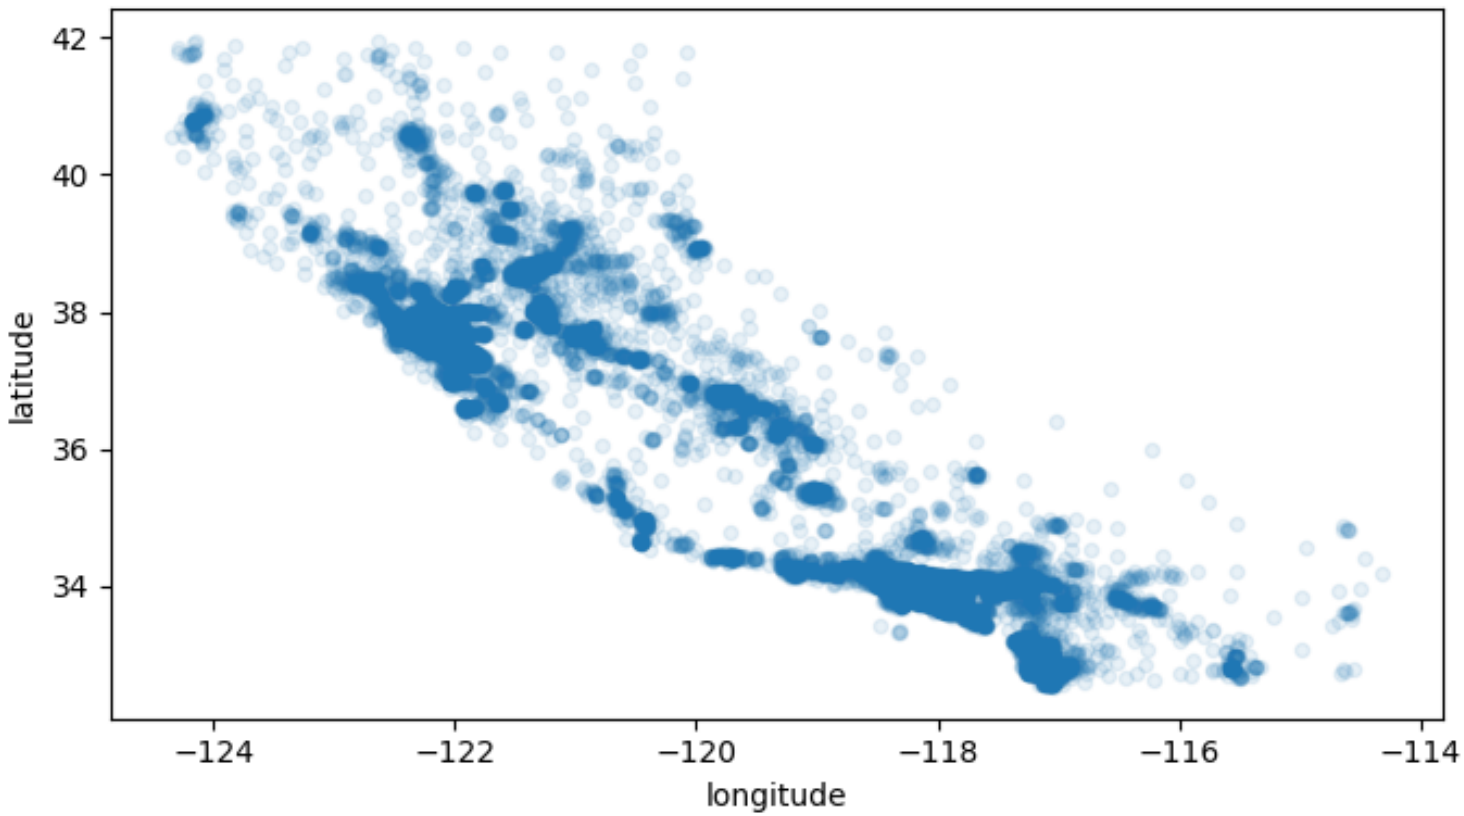

Dane, ceny

```
df.plot(kind="scatter", x="longitude", y="latitude",
        alpha=0.4, figsize=(7,3), colorbar=True,
        s=df["population"]/100, label="population",
        c="median_house_value", cmap=plt.get_cmap("jet"))
f = "housing_price.png"
plt.tight_layout()
plt.savefig(f)
print(f)
```

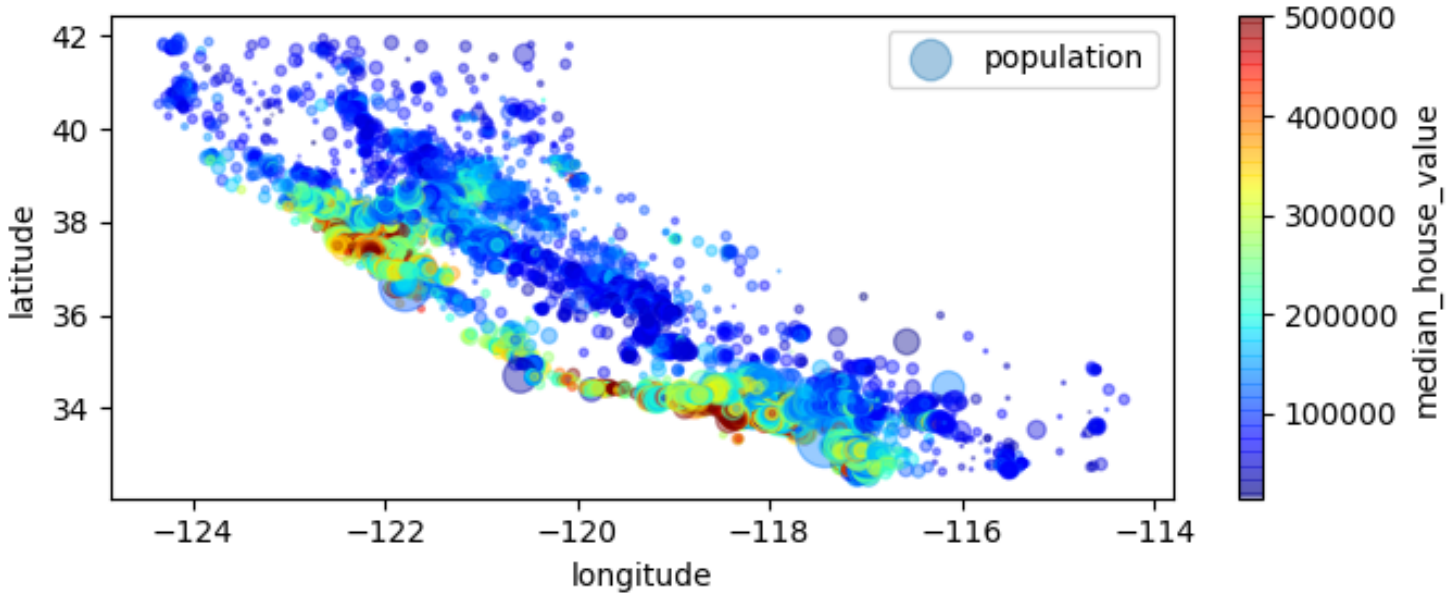

Dane, macierz korelacji

Uwaga: pokazuje jedynie zależności liniowe!

```
print(df.corr()["median_house_value"].
      sort_values(ascending=False))
```

```
median_house_value    1.000000
median_income         0.688075
total_rooms           0.134153
housing_median_age    0.105623
households            0.065843
total_bedrooms        0.049686
population           -0.024650
longitude            -0.045967
latitude             -0.144160
Name: median_house_value, dtype: float64
```

Zbiór uczący i testujący

```
1  from sklearn.model_selection import train_test_split
2  train_set, test_set = train_test_split(df,
3                                         test_size=0.2,
4                                         random_state=42)
5  print(len(train_set),len(test_set))
```

```
16512 4128
```